

INTRODUCCIÓN AL ANÁLISIS DE DATOS

Carlos Fernando Vásquez Guerra




ANÁLISIS DE DATOS



<https://legoviews.com/2013/04/06/put-knowledge-into-action-and-enhance-organisational-wisdom-lsp-and-dikw/>

ANÁLISIS DE DATOS





<https://marketingplatform.google.com/about/analytics/>

ANÁLISIS DE DATOS




```
1  <!-- Google tag (gtag.js) -->
2  <script async src="https://www.googletagmanager.com/gtag/js?id=G-XXXXXXXXX"></script>
3  <script>
4      window.dataLayer = window.dataLayer || [];
5      function gtag(){dataLayer.push(arguments);}
6      gtag('js', new Date());
7
8      gtag('config', 'G-25PV1319BX');
9  </script>
```



ANÁLISIS DE DATOS



DATA ANALYSIS LIFECYCLE




<https://graduate.northeastern.edu/knowledge-hub/data-analysis-project-lifecycle/>



<https://www.knime.com/blog/the-data-lifecycle>

METODOLOGÍAS DE MINERÍA DE DATOS O CIENCIA DE DATOS

Metodología **CRISP-DM** (Cross-Industry Standard Process for Data Mining)



Guía estructurada para proyectos de minería de datos que facilita la gestión y el análisis de datos para extraer conocimiento y tomar decisiones informadas

METODOLOGÍAS DE MINERÍA DE DATOS O CIENCIA DE DATOS

Metodologías proporciona un marco de trabajo para guiar el proceso de extracción de conocimiento a partir de conjuntos de datos

<https://www.linkedin.com/pulse/metodolog%C3%ADas-kdd-semma-y-crisp-dm-emil-j-yanez-guarecuo-guyme/>

CRISP-DM


CROSS-INDUSTRY STANDARD
PROCESS FOR DATA MINING



<https://bsginstitute.com/bs-campus/blog/Metodolog%C3%ADas-CRISP-DM-Gu%C3%ADas-para-Cient%C3%ADficos-de-Datos-0>

KDD

KNOWLEDGE DISCOVERY IN
DATABASES




<https://www.scaler.com/topics/data-mining-tutorial/kdd-in-data-mining/>

SEMMA

SAMPLE, EXPLORE, MODIFY, MODEL
AND ACCESS

SEMMA Methodology of Data Mining Process

Sample Data, Explore, Modify Data, Model building, Assess




Get these slides & icons at www.infodiagram.com


<https://www.infodiagram.com/slides/semma-methodology-of-data-mining-process/>

METODOLOGÍAS DE MINERÍA DE DATOS O CIENCIA DE DATOS

Metodología	Descripción	Enfoque	Inicio	Finalidad principal
KDD	Marco académico general para descubrir conocimiento en datos.	Todo el proceso: desde la selección hasta la interpretación.	Desde recolección de datos.	Conocimiento nuevo.
CRISP-DM	Estándar de la industria para proyectos de minería de datos.	Orientación al negocio y resultados aplicables. Entender el negocio + Minería de datos.	Desde objetivos del negocio.	Resultados accionables en negocio.
SEMMA	Proceso propuesto por SAS para minería de datos técnica.	Preparar y construir modelos predictivos, más técnico. Optimizar construcción y evaluación de modelos.	Desde muestra de datos existente.	Modelos predictivos robustos.




Utilizar para empresas o proyectos orientado a negocio y se necesite alinear el análisis con objetivos estratégicos.
La mejor opción general hoy en día para proyectos profesionales.



Utilizar para proyectos de investigación, científico, o si se desea hacer todo el proceso desde cero, incluyendo descubrimiento de patrones desconocidos

SEMMA Methodology of Data Mining Process
Sample Data, Explore, Modify Data, Model building, Assess



Get these slides & icons at www.InfoDiagram.com

Utilizar cuando se tiene los datos preparados (por ejemplo, en una base SAS), y el objetivo principal es desarrollar modelos predictivos o clasificadores eficientes, sin tanto enfoque en el negocio o el descubrimiento de patrones nuevos

METODOLOGÍAS DE MINERÍA DE DATOS O CIENCIA DE DATOS

OBJETIVOS SMART Técnica para definir objetivos de forma clara y alcanzable.

Objetivo NO SMART:

"Quiero mejorar en ciencia de datos."

Objetivo SMART:

"Quiero completar un curso de ciencia de datos de 20 horas en línea en los próximos 2 meses para mejorar mis habilidades en análisis de datos."

- Específico: curso de ciencia de datos.
- Medible: 20 horas.
- Alcanzable: realista con el tiempo disponible.
- Relevante: mejora habilidades profesionales.
- Tiempo definido: 2 meses.

¿Dónde se usa la estrategia SMART?


- Gestión de proyectos.
- Definición de metas personales o profesionales.
- Planificación estratégica en empresas.
- Evaluación de desempeño.

S	Specific	Make your goal specific and narrow for more effective planning	
M	Measurable	Make sure your goal and progress are measurable	
A	Achievable	Make sure you can reasonably accomplish your goal within a certain time frame	
R	Relevant	Your goal should align with your values and long-term objectives	
T	Time-based	Set a realistic but ambitious end date to clarify task prioritization and increase motivation	




<https://www.indeed.com/career-advice/career-development/how-to-write-smart-goals>

FUENTES DE DATOS




FUENTES DE DATOS



<https://www.infectious-diseases-toolkit.org/data-sources/human-clinical-and-health-data>

LIMPIEZA DE DATOS


1. Manejo de datos faltantes
2. Identificación y tratamiento de valores atípicos
3. Estandarización de formatos
4. Corrección de errores tipográficos
5. Eliminación de duplicados
6. Normalización de datos



<https://www.geeksforgeeks.org/best-data-cleaning-techniques-for-preparing-your-data/>


LIMPIEZA DE DATOS

MISSING VALUES




LIMPIEZA DE DATOS

OUTLIER DETECTION




<https://medium.com/data-science/outlier-detection-with-scikit-learn-and-matplotlib-a-practical-guide-382d1411b8ec>




<https://www.mdpi.com/2224-2708/11/1/4>

LIMPIEZA DE DATOS


OUTLIER DETECTION




<https://www.almabetter.com/bytes/articles/outlier-detection-methods-and-techniques-in-machine-learning-with-examples>



<https://www.scaler.com/topics/data-science/handling-outliers-in-data-science/>



<https://spotintelligence.com/2024/05/21/isolation-forest/>



<https://pieriaintraining.com/dbscan-for-outlier-detection-in-python-and-scikit-learn-machine-learning-in-python/>

LIMPIEZA DE DATOS

FEATURE SCALING

$$x_{\text{norm}} = \frac{x - \min(x)}{\max(x) - \min(x)}$$

#	Emp	Age	Salary
1	Emp1	44	73000
2	Emp2	27	47000
3	Emp3	30	53000
4	Emp4	38	62000
5	Emp5	40	57000
6	Emp6	35	53000
7	Emp7	48	78000

Normalization

Age	Normalized Age	Salary	Normalized Salary
44	0.80952381	73000	0.838709677
27	0	47000	0
30	0.142857143	53000	0.193548387
38	0.523809524	62000	0.483870968
40	0.619047619	57000	0.322580645
35	0.380952381	53000	0.193548387
48	1	78000	1


Range 0-1

Range 0-1

How to calculate Normalized value?
X = 35, min = 27, max = 48 for column Age.
$$X_{\text{norm}}(\text{for } 35) = \frac{35-27}{48-27} = 0.3809$$


LIMPIEZA DE DATOS

ESTANDARIZACIÓN VS NORMALIZACIÓN



<https://www.simplilearn.com/normalization-vs-standardization-article>

Feature scaling



<https://python.plainenglish.io/do-standardization-and-normalization-transform-the-data-into-normal-distribution-cb5857ab9c63>

LIMPIEZA DE DATOS

Imaginemos que estamos trabajando con los datos de **ventas de un supermercado**. Al examinar los datos, podríamos encontrar:

1. Valores faltantes en la columna 'Edad del cliente'
 2. Inconsistencias en el formato de las fechas (algunas en DD/MM/YYYY, otras en MM/DD/YYYY)
 3. Errores tipográficos en los nombres de productos ('Manzana' y 'Manzna')
 4. Valores atípicos en la columna 'Cantidad vendida' (por ejemplo, 1000 unidades de leche en una sola transacción)
 5. Duplicados en las transacciones
-

LIMPIEZA DE DATOS

Para limpiar y preparar estos datos, podríamos:

1. Imputar los valores faltantes de edad utilizando la mediana de edad de los clientes.
 2. Estandarizar todas las fechas a un formato único.
 3. Corregir los errores tipográficos en los nombres de productos.
 4. Investigar y posiblemente eliminar o ajustar los valores atípicos.
 5. Eliminar las transacciones duplicadas.
-


LIMPIEZA DE DATOS

Y a ti, ¿Con qué te has enfrentado?



LIMPIEZA DE DATOS

REGLAS DE CODD



<https://medium.com/itversity/50-years-of-codds-rules-transforming-data-management-and-the-global-economy-7745b6708fc3>

Regla 0: Fundamento Relacional: La base de datos debe gestionarse solo mediante su modelo relacional, utilizando la mediana de edad de los clientes.

Regla 1: Representación de la Información: Toda la información se representa en tablas.

Regla 2: Acceso Garantizado: Cada dato debe ser accesible especificando la tabla, la columna y el valor de la clave primaria.

Regla 3: Tratamiento Sistemático de Valores Nulos: Los valores nulos deben ser soportados de forma uniforme.

Regla 4: Catálogo Basado en el Modelo Relacional: La descripción de la base de datos debe estar almacenada en tablas (metadatos).

Regla 5: Lenguaje Completo de Datos: Debe existir un lenguaje que soporte todas las operaciones (consulta, actualización, etc.)

Regla 6: Actualización de Vistas: Las vistas deben poder actualizarse si es lógico hacerlo.

Regla 7: Inserción, Actualización y Eliminación de Datos: Las operaciones básicas deben ser soportadas de manera sencilla.

Regla 8: Independencia Física de Datos: Cambios en el almacenamiento físico no deben afectar a las aplicaciones.

Regla 9: Independencia Lógica de Datos: Cambios en las estructuras lógicas (por ejemplo, agregar una columna) no deben afectar a las aplicaciones existentes.

Regla 10: Independencia de la Integridad: Las reglas de integridad deben almacenarse en el catálogo y no en el código de aplicación.

Regla 11: Independencia de la Distribución: La distribución de datos en varios lugares debe ser transparente para el usuario.

Regla 12: No Subversión: No debe existir una vía para saltarse las reglas del modelo relacional.

EDA


 @citizendatascientist

 @saurabhmoody

Exploratory Data Analysis (EDA): Meaning and Steps

Exploratory Data Analysis (EDA) is the first step in a data science project. It involves **analysing** and **visualizing data** to understand its main features, spot patterns, detect outliers, and find relationships between variables. This helps prepare the data for deeper analysis or modelling.

Steps for performing Exploratory Data Analysis



```
graph TD; RAW[RAW DATA] --> CON[CONCLUSIONS]; 1((1)) --> 2((2)); 2 --> 3((3)); 3 --> 4((4)); 4 --> 5((5)); 5 --> 6((6)); 6 --> 7((7)); 7 --> 8((8));
```

The flowchart illustrates the 8 steps of EDA:


1. Understand the problem and data
2. Import and Inspect Data
3. Handle missing data
4. Explore data characteristics
5. Perform data transformation
6. Visualise data relationships
7. Handling Outliers
8. Communicate Findings & Insights



[Sign Up with Super.ai](#)
Try the Data Story yourself

EDA

1. Visualizar la distribución de variables individuales
2. Examinar las relaciones entre pares de variables
3. Identificar patrones, tendencias y anomalías en los datos
4. Generar hipótesis para un análisis más profundo




https://www.researchgate.net/figure/Exploratory-Data-Analysis-EDA-steps-source-7_fig4_352546274

Data Analytics Tools List




<https://dataanalyticsmasters.in/data-analytics-tools-list/>



<https://www.r-bloggers.com/2015/08/five-interactive-r-visualizations-with-d3-ggplot2-rstudio/>


EDA

Blue wave




Where penalties are saved

World Cup shootout misses and saves, 1982-2014




Fast-growing cities face worse climate risks

Population growth 2018-2035 over climate change vulnerability



MPs rejected Theresa May's deal by 230 votes



Earnings vary across units even within subjects

Impact on men's earnings relative to the average degree



TÉCNICAS:

1. Crear histogramas para visualizar la distribución de edades de los clientes o los montos de compra.
 2. Utilizar gráficos de dispersión para examinar la relación entre la edad del cliente y el monto de compra.
 3. Crear gráficos de barras para ver qué productos se venden más en diferentes días de la semana.
 4. Utilizar mapas de calor para visualizar las horas pico de ventas durante la semana.
-

EDA

INSIGHTS:

- La mayoría de nuestros clientes tienen entre 30 y 50 años.
 - Hay una correlación positiva entre la edad del cliente y el monto de compra.
 - Los productos frescos se venden más los fines de semana.
 - Las horas pico de ventas son diferentes entre semana y los fines de semana.
-

FORMULAR HIPÓTESIS:

- '¿Deberíamos ajustar nuestra estrategia de marketing para atraer a clientes más jóvenes?'
 - '¿Podríamos aumentar las ventas ofreciendo promociones de productos frescos los viernes?'
 - '¿Necesitamos ajustar nuestros horarios de personal para manejar mejor las horas pico?'
-

MODELADO ESTADÍSTICO Y ANÁLISIS

1. PRUEBAS DE HIPÓTESIS

2. ANÁLISIS DE REGRESIÓN

3. ANÁLISIS DE SERIES TEMPORALES

4. MÉTODOS DE APRENDIZAJE AUTOMÁTICO


5. ANÁLISIS MULTIVARIANTE

MODELADO ESTADÍSTICO Y ANÁLISIS


1. PRUEBAS DE HIPÓTESIS

Choosing a statistical test

This flowchart helps you choose among parametric tests



<https://www.scribbr.com/statistics/statistical-tests/>



<https://data-flair.training/blogs/hypothesis-testing-in-r/>

Hypothesis Testing

[hī-'pā-thā-sās 'te-stīŋ]

An act in statistics whereby an analyst tests an assumption regarding a population parameter.

Investopedia

<https://www.investopedia.com/terms/h/hypothesistesting.asp>

P-Value

[pē 'vāl-(l)jū]

A statistical measure used to determine the likelihood that an observed outcome is the result of chance.


Investopedia

<https://www.investopedia.com/terms/p/p-value.asp>

MODELADO ESTADÍSTICO Y ANÁLISIS

2. ANÁLISIS DE REGRESIÓN

Types of Regression Models



<https://www.dasca.org/world-of-data-science/article/essential-regression-analysis-techniques-for-data-science>

Regression

[ri-'gre-shən]


A statistical method used in finance, investing, and other disciplines that attempts to determine the strength and character of the relationship between one dependent variable (usually denoted by Y) and a series of other variables (known as independent variables).

Investopedia


<https://www.investopedia.com/terms/r/regression.asp>

MODELADO ESTADÍSTICO Y ANÁLISIS

3. ANÁLISIS DE SERIES TEMPORALES




<https://medium.com/@datasciencewizards/introduction-to-time-series-analysis-i-82d614d462b0>



<https://www.investopedia.com/terms/t/timeseries.asp>

MODELADO ESTADÍSTICO Y ANÁLISIS


4. MÉTODOS DE APRENDIZAJE AUTOMÁTICO




<https://botpenguin.com/glossary/machine-learning-methods>

MODELADO ESTADÍSTICO Y ANÁLISIS


5. ANÁLISIS MULTIVARIANTE




<https://medium.com/getdatatron/multivariate-analysis-techniques-for-exploring-data-1878061366cf>



<https://www.mindforceresearch.com/services/data-analysis/correspondence-analysis>



<https://spotintelligence.com/2023/11/28/factor-analysis/>



https://www.wikiwand.com/en/articles/T-distributed_stochastic_neighbor_embedding

MODELADO ESTADÍSTICO Y ANÁLISIS


MODELOS

1. Regresión lineal para predecir el monto de compra basado en características del cliente.
2. Análisis de series temporales para pronosticar las ventas futuras.
3. Árboles de decisión para segmentar a los clientes en grupos con comportamientos de compra similares.
4. Análisis de cesta de mercado para identificar productos que se compran frecuentemente juntos.

WHAT FOR?

- Nuestro modelo de regresión podría revelar que, controlando por otros factores, por cada año de edad adicional, los clientes gastan en promedio \$5 más por visita.
 - El análisis de series temporales podría mostrar un patrón estacional en las ventas, con picos significativos antes de las festividades.
 - Los árboles de decisión podrían identificar segmentos de clientes como 'compradores frecuentes de productos orgánicos' o 'cazadores de ofertas'.
 - El análisis de cesta de mercado podría revelar que los clientes que compran pan a menudo también compran leche.
-

VISUALIZACIÓN DE DATOS



<https://nightingaledvs.com/review-data-visualization-power-bi/>

VISUALIZACIÓN DE DATOS

33 stunning visualizations



datasciencedojo
data science for everyone

10 Copyrights Reserved. <https://datasciencedojo.com>


<https://datasciencedojo.com/blog/33-data-visualization-ways/>




<https://datavizcatalogue.com>



<https://100.datavizproject.com>




<https://www.storytellingwithdata.com>




VISUALIZACIÓN DE DATOS

La **visualización de datos efectiva** implica:

1. Elegir el tipo de gráfico adecuado para los datos y el mensaje
2. Usar color, forma y tamaño de manera efectiva
3. Eliminar el 'chartjunk' (elementos visuales innecesarios)
4. Proporcionar contexto y etiquetas claras




! ineffective




✓ effective

profit by year




! ineffective

profit by year




✓ effective

sales by region and category



! ineffective


sales by region and category



✓ effective

VISUALIZACIÓN DE DATOS

What Makes a Good Visualization?




David McCandless
InformationIsBeautiful.net

find out more
bit.ly/KIB_Books

<https://informationisbeautiful.net/>

VISUALIZACIÓN DE DATOS

PRINCIPIOS DE GESTALT



VISUALIZACIÓN DE DATOS


PROPUESTAS

1. Un gráfico de líneas para mostrar las tendencias de ventas a lo largo del tiempo
2. Un gráfico de barras apiladas para comparar las ventas por categoría de producto
3. Un mapa de calor para visualizar las horas pico de ventas durante la semana
4. Un gráfico de dispersión para mostrar la relación entre la edad del cliente y el gasto


WHAT FOR?

- Nuestro gráfico de líneas podría mostrar claramente los picos de ventas estacionales.
 - El gráfico de barras apiladas podría revelar que, aunque los productos frescos generan más ingresos, los productos envasados tienen un margen de beneficio más alto.
 - El mapa de calor podría mostrar que las ventas son más altas los viernes por la tarde y los sábados por la mañana.
 - El gráfico de dispersión podría visualizar la correlación positiva entre la edad y el gasto que descubrimos en nuestro análisis estadístico.
-


KPI



KPI



KPI




<https://dashthis.com/blog/how-to-create-the-perfect-kpi-report/>












RECOMENDACIONES











coursera




RECOMENDACIONES



RECOMENDACIONES



RECOMENDACIONES



<https://ggplot2-book.org>




<https://rpubs.com/CarlosFVG>

BOOKDOWN

Write HTML, PDF, ePub, and Kindle books with R Markdown

The **bookdown** package is an [open-source R package](#) that facilitates writing books and long-form articles/reports with R Markdown. Features include:

- Generate printer-ready books and ebooks from R Markdown documents.
- A markup language easier to learn than LaTeX, and to write elements such as section headers, lists, quotes, figures, tables, and citations.
- Multiple choices of output formats: PDF, LaTeX, HTML, EPUB, and Word.
- Possibility of including dynamic graphics and interactive applications (HTML widgets and Shiny apps).
- Support a wide range of languages: R, C/C++, Python, Fortran, Julia, Shell scripts, and SQL, etc.
- LaTeX equations, theorems, and proofs work for all output formats.
- Can be published to GitHub, bookdown.org, and any web servers.
- Integrated with the RStudio IDE.
- One-click publishing to <https://bookdown.org>.



<https://es.r4ds.hadley.nz/15-factors.html>

<https://bookdown.org>



<https://github.com/CarlosFernandoVG>
