
RECOPILACIÓN DE DATOS


Carlos Fernando Vásquez Guerra



DATA ETHICS & DATA PRIVACY

El caso de TARGET



A photograph of a digital screen displaying the formula for Bayes' theorem in blue ink:
$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

La aplicación de las matemáticas a dicho consorcio de datos rápidamente creciente, sin embargo, no está exenta de controversia. Por ejemplo, en febrero The New York Times publicó una investigación escrita por Charles Duhigg sobre el valor de los datos del cliente para las grandes corporaciones, y cómo esas corporaciones pueden usar tus datos en una forma instintivamente espeluznante. La empresa en la que se enfoca es Target y su deseo de identificar a mujeres embarazadas basándose en sus hábitos de compra.

Target pudo haber tenido éxito en su meta. Como escribe Duhigg, el embarazo de una cliente adolescente en Minneapolis, Estados Unidos, fue descubierto porque le llegaron cupones a su casa. Su padre estaba molesto justificadamente al ver que Target ofrecía a su hija menor de edad descuentos en pañales y cunas, aunque quizá estuvo más molesto cuando descubrió que Target conocía más sobre la vida personal de su hija de lo que él sabía.

¿Cómo es posible para Target (o cualquier empresa, para el caso) sacar conclusiones tan precisas sobre sus clientes de su comportamiento al comprar? Duhigg hace mención de que Target está haciendo alguna especie de magia matemática para asignar a cada cliente mujer una “puntuación de embarazo. En esencia, lo que estamos buscando es una forma de asignar una probabilidad a un resultado (por ejemplo, el embarazo) que es flexible, y puede cambiar a medida que conocemos más información (por ejemplo, hábitos de compras). Una forma de hacer esto es aplicar el Teorema de Bayes, un resultado poderoso que nos permite modificar la probabilidad de algunas hipótesis a medida que obtenemos más información.

<https://cnnespanol.cnn.com/2012/04/23/como-se-entera-una-tienda-antes-que-tus-padres-de-que-estas-embarazada>

DATA ETHICS & DATA PRIVACY

Anónimos pero no tanto



Datos

Daniel Yankelevich

Abril 2021



En 2005 la Universidad de Harvard inició un estudio de alto impacto sobre el genoma humano, denominado Personal Genome Project, para el cual reclutó a 2500 donantes voluntarios de material genético. A ellos se les aclaró desde el inicio que la información que proporcionarían iba a mantenerse en el anonimato: en efecto, a partir del material genético se puede determinar la predisposición a enfermedades o a distintas condiciones, además de que, en el cuestionario, los voluntarios daban información sobre alcoholismo y uso de drogas, entre otros datos personales, todos contenidos sensibles cuya difusión podía impactar negativamente en la vida de esas personas¹.

El equipo del Personal Genome Project borró nombres, números de documento y otros datos de los donantes considerados "personales". Como se quería conservar cierta información sobre distribución geográfica, se enmascararon los domicilios y se conservó solo la información del código postal. El director del proyecto expresó entonces sus reparos sobre el riesgo de que alguien pudiera reidentificar los registros y acceder a los datos privados asociados a cada persona. Ese riesgo se materializó mucho más rápido de lo esperado, cuando el laboratorio de Data Privacy de Harvard, dirigido por Latanya Sweeney, en un experimento que intentaba poner a prueba la confiabilidad de estos procedimientos, logró reidentificar un 43% de los datos de una muestra de donantes que tomó. La fecha de nacimiento, el código postal y el género resultaron suficientes para identificar los nombres de las personas (consultando información electoral y otras fuentes) (Sweeney et al., 2013). De hecho, en otro trabajo, Sweeney (2000) estimó que un 87% de la población de los Estados Unidos podía identificarse en forma inequívoca en función de esos tres datos.



The Harvard
Personal Genome Project
we are open for science

DATA ETHICS & DATA PRIVACY

Anónimos pero no tanto



Datos

Daniel Yankelevich

Abril 2021



Netflix

En 2006 Netflix propuso un concurso que desembocaría finalmente en las actuales competencias de ciencia de datos, el sitio Kaggle.com² y las contrataciones “abiertas”. Desde hacía tiempo, Netflix venía trabajando en su algoritmo de recomendación que, según las películas y series que una persona había visto, intentaba predecir qué otras películas o series le gustaría ver. Mejorar este algoritmo era complejo y caro. La competencia propuesta tenía las siguientes reglas: podía inscribirse cualquier grupo de ciencias de datos de cualquier lugar del mundo; cada grupo recibiría la base de datos con las valoraciones que hacían los clientes de las películas que habían visto (por ejemplo, el cliente 11234 le había puesto cinco estrellas a *El Señor de los anillos*, tres estrellas a *Piratas del Caribe* y ninguna estrella a *Diario de una pasión*, después de haber visto las tres películas), excepto por una pequeña porción de datos que Netflix se “guardaba” para sí mismo. Obviamente, no se daba a los concursantes información personal de los usuarios (como nombre o región geográfica en que

Finalmente, dos equipos lograron exactamente el mismo error, pero de acuerdo con las reglas en ese caso el primero en haber sido propuesto resultaba ganador; uno fue subido al sitio 20 minutos antes que el otro, y se hizo acreedor al millón de dólares.

Esta competencia de Netflix dio origen no sólo a una forma de relación con grupos de ciencia de datos sino también a nuevas técnicas y tecnología para sistemas de recomendación. Sin embargo, el final no es feliz. Entre los más de 2500 equipos de todo el mundo que se inscribieron para resolver el problema, algunos usaron los datos para otros *experimentos*. Narayanan y Shmatikov, dos investigadores de la Universidad de Texas, por ejemplo, mostraron que con la ayuda de una base de datos externa (en este caso, IMDb, un sitio online con información de películas), podían identificar registros correspondientes a un grupo de personas incluidas en la base publicada por Netflix para la competencia, aun con muy poca información sobre ellas (Narayanan y Shmatikov, 2008). Al identificarlas se revelaban además preferencias políticas, sexuales, y otro tipo de información personal. Además, a partir de esta experiencia los investigadores presentaron una serie de estrategias para reidentificar datos personales que podían aplicarse en situaciones similares.




DATA ETHICS & DATA PRIVACY



<https://www.aepd.es/guias/10-malentendidos-anonimizacion.pdf>

El algoritmo de Amazon al que no le gustan las mujeres




No es la primera vez que la inteligencia artificial resulta sexista.

<https://www.bbc.com/mundo/noticias-45823470>

DATA STRUCTURES


Las **estructuras de datos** se refiere a cómo se organizan y almacenan los datos en memoria o en algoritmos para su procesamiento eficiente.

- Listas enlazadas




- Pilas y colas

Pilas



Colas




- Vectores / Arreglos (arrays)
 - Matrices

What is an array?

Dimensions	Example	Terminology										
1	<table><tr><td>0</td><td>1</td><td>2</td></tr></table>	0	1	2	Vector							
0	1	2										
2	<table><tr><td>0</td><td>1</td><td>2</td></tr><tr><td>3</td><td>4</td><td>5</td></tr><tr><td>6</td><td>7</td><td>8</td></tr></table>	0	1	2	3	4	5	6	7	8	Matrix	
0	1	2										
3	4	5										
6	7	8										
3	<table><tr><td>0</td><td>1</td><td>2</td></tr><tr><td>3</td><td>4</td><td>5</td></tr><tr><td>6</td><td>7</td><td>8</td></tr></table>	0	1	2	3	4	5	6	7	8	3D Array (3 rd order Tensor)	
0	1	2										
3	4	5										
6	7	8										
N	<table><tr><td><table><tr><td>...</td></tr></table></td><td>...</td><td><table><tr><td>...</td></tr></table></td></tr><tr><td><table><tr><td>...</td></tr></table></td><td>...</td><td><table><tr><td>...</td></tr></table></td></tr></table>	<table><tr><td>...</td></tr></table>	...	...	<table><tr><td>...</td></tr></table>	...	<table><tr><td>...</td></tr></table>	...	...	<table><tr><td>...</td></tr></table>	...	ND Array
<table><tr><td>...</td></tr></table>	...	...	<table><tr><td>...</td></tr></table>	...								
...												
...												
<table><tr><td>...</td></tr></table>	...	...	<table><tr><td>...</td></tr></table>	...								
...												
...												


- Grafos
 - Árboles (binarios, B-trees, etc.)



<https://medium.com/basecs/a-gentle-introduction-to-graph-theory-77969829ead8>

- Hash tables

Components of Hashing



DATA STRUCTURES

Importancia de las Estructuras de Datos

1. Eficiencia en el Almacenamiento:

Las estructuras adecuadas optimizan el uso de memoria y espacio de almacenamiento.

Matriz dispersa (Sparse Matrix)
vs. Matriz densa

Dense Matrix

1	2	31	2	9	7	34	22	11	5
11	92	4	3	2	2	3	3	2	1
3	9	13	8	21	17	4	2	1	4
8	32	1	2	34	18	7	78	10	7
9	22	3	9	8	71	12	22	17	3
13	21	21	9	2	47	1	81	21	9
21	12	53	12	91	24	81	8	91	2
61	8	33	82	19	87	16	3	1	55
54	4	78	24	18	11	4	2	99	5
13	22	32	42	9	15	9	22	1	21

Sparse Matrix

1	.	3	.	9	.	3	.	.	.
11	.	4	.	.	.	.	.	2	1
.	.	1	.	.	.	4	.	1	.
8	.	.	.	3	1	.	.	.	.
.	.	.	9	.	.	1	.	17	.
13	21	.	9	2	47	1	81	21	9
.	.	.	.	.	.	.	.	.	.
.	.	.	.	19	8	16	.	.	55
54	4	.	.	.	11	.	.	.	.
.	.	2	.	.	.	.	22	.	21

<https://cmdlinetips.com/2018/03/sparse-matrices-in-python-with-scipy/>

Sparse Matrix

$\begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 5 & 0 & 2 \\ 9 & 0 & 0 & 6 \\ 7 & 0 & 0 & 0 \end{bmatrix}$	→	Row	Column	Value	0	1	1	2	1	5	2	3	2	3	0	9	3	3	6	4	0	7
Row	Column	Value																				
0	1	1																				
2	1	5																				
2	3	2																				
3	0	9																				
3	3	6																				
4	0	7																				

<https://botpenguin.com/glossary/sparse-matrix>

- **Problema:** Si tienes millones de usuarios y productos, la mayoría de las celdas de la matriz de usuario-producto estarán vacías (sin interacción).
- **Solución:** Usar estructuras para matrices dispersas, que solo almacenan posiciones con valor distinto de cero.
- **Beneficio:** Ahorro enorme en memoria (puede ser 90% o más), mejora el rendimiento computacional.
- **Ejemplo de uso:** Sistemas de recomendación (como los de Netflix o Spotify).


DATA STRUCTURES

Importancia de las Estructuras de Datos













2. Facilidad de Acceso: Permiten recuperar información rápidamente.

Ordenamiento e
indexación

Binary
Search
Tree



<https://www.geeksforgeeks.org/introduction-to-binary-search-tree/>

								
	Insertion	Selection	Bubble	Shell	Merge	Heap	Quick	Quick3
 Random								
 Nearly Sorted								
 Reversed								
 Few Unique								

- **Problema:** Consultas frecuentes sobre grandes volúmenes de datos deben acceder a disco eficientemente.
- **Solución:** Se usan B-trees para organizar índices de manera jerárquica.
- **Beneficio:** Menos lecturas de disco (espacio $O(\log n)$), menor uso de memoria caché, búsqueda más rápida.
- **Ejemplo de uso:** Motores de bases de datos como MySQL, PostgreSQL o SQLite

<https://medium.com/@miles.pucarelli/lets-build-sorting-algorithms-in-javascript-b00d04e4a8de>

<https://yuminlee2.medium.com/sorting-algorithms-summary-f17ea88a9174>

DATA STRUCTURES

Importancia de las Estructuras de Datos

3. Análisis Efectivo: Diferentes estructuras facilitan distintos tipos de análisis.

Bitmaps para variables categóricas

Timestamp	User	Source	Device	Region
2023-07-01 09:15:23	<u>JohnDoe</u>	Google	Desktop → 0	USA
2023-07-01 09:20:10	<u>JaneSmith</u>	Direct	Mobile → 1	Canada
2023-07-02 09:50:18	<u>JohnDoe</u>	Google	Mobile → 1	Australia
2023-07-02 10:05:36	<u>JaneSmith</u>	Direct	Desktop → 0	Germany
2023-07-03 10:12:59	<u>SamJohnson</u>	Google	Tablet → 2	France
...	...	...	...	...

Bitmap index {
Value = "Desktop": [1,0,0,1,0]
Value = "Mobile": [0,1,1,0,0]
Value = "Tablet": [0,0,0,0,1]

<https://imply.io/developer/articles/apache-druid-making-1000-qps-for-analytics-look-easy/>

- **Problema:** Guardar datos categóricos (ej. "género", "país", "tipo de producto") como texto consume mucho espacio.
- **Solución:** Representar categorías como vectores de bits (bitmaps).
- **Beneficio:** Ahorro de espacio; permite operaciones conjuntas (AND, OR, NOT) súper rápidas y compactas.
- **Ejemplo de uso:** Motores analíticos como Apache Druid o ClickHouse.


DATA STRUCTURES

Importancia de las Estructuras de Datos

4. Visualización: La estructura de los datos influye en las opciones de visualización disponibles.

Grafos con listas de adyacencia vs. matrices de adyacencia


- **Problema:** Una matriz de adyacencia de n nodos ocupa $O(n^2)$ espacio, aunque haya pocos enlaces.
- **Solución:** Usar listas de adyacencia, que solo almacenan conexiones existentes.
- **Beneficio:** Reducción significativa del uso de memoria si el grafo es poco denso (sparse).
- **Ejemplo de uso:** Representación de redes sociales, mapas de rutas o conexiones en telecomunicaciones.



(a) Un grafo no dirigido


$$\begin{pmatrix} 0 & 1 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 1 & 0 & 1 & 0 \\ 0 & 1 & 1 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 1 & 1 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 \end{pmatrix}$$

(b) Su matriz de adyacencia




http://aniei.org.mx/paginas/uam/CursoAA/curso_aa_23.html

DATA TYPES



<https://www.docsumo.com/blogs/data-extraction/structured-vs-unstructured-vs-semistructured>

Structured data



Characteristics

Predefined data models
Easy to search
Text-based
Shows what's happening

Resides in

Relational databases
Data warehouses

Stored in

Rows and columns

Examples

Dates, phone numbers, social security numbers, customer names, transaction info

Unstructured data



Characteristics

No predefined data models
Difficult to search
Text, pdf, images, video
Shows the why

Resides in

Applications
Data warehouses and lakes


Stored in

Various forms

Examples

Documents, emails and messages, conversation transcripts, image files, open-ended survey answers

Semi-structured data



Characteristics

Loosely organized
Meta-level structure that can contain unstructured data
HTML, XML, JSON

Resides in

Relational databases
Tagged-text format

Stored in

Abstracts & figures

Examples

Server logs, tweets organized by hashtags, emails sorting by folders (inbox; sent; draft)

COMMON DATABASES

Tabular data



NoSQL Databases



Graph Databases



COMMON DATABASES


NoSQL Databases: Teorema CAP

Todos los sistemas distribuidos no pueden garantizar a la vez que haya **consistencia**, **disponibilidad** y **tolerancia a particiones** (consistency-availability-partition tolerance).

Consistencia (CONSISTENCY): sin importar qué servidor reciba la petición, cuando se realiza una consulta o se hace una inserción, el sistema siempre debe devolver la misma información de respuesta.

Disponibilidad (AVAILABILITY): la caída de uno o más nodos no debe ser un impedimento para que los clientes puedan leer y escribir peticiones. Es la disponibilidad de los datos en un nodo.


Tolerancia a particiones (PARTITION): hace referencia al hecho de que el sistema tiene que seguir funcionando, aunque existan fallos o caídas parciales que dividan el sistema. La división por particiones es una característica de los sistemas distribuidos que permite canalizar grandes flujos de peticiones.



<https://www.linkedin.com/pulse/cap-theorem-optimizing-database-selection-enhanced-application-kar--ey86f/>

REGULAR EXPRESSIONS

Regular Expression E-mail Matching Example



<https://www.computerhope.com/jargon/r/regex.htm>



<https://regexcrossword.com/playerpuzzles>



<https://regexone.com>



<https://regexr.com>

regex₁₀₁ /r/XBCq2F/1 python

date pattern

```
r"(?  
=\b(jan|feb|mar|apr|may|jun|jul|aug|sep|oct|nov|dec  
|\d{4}|\d{1,2}))\w*[\t\.\-\/\.\,;\:|-|+|_]+  
(\d{1,2}|jan|feb|mar|apr|may|jun|jul|aug|sep|oct|no  
v|dec)\w*[\t\.\-\/\.\,;\:|-|+|_]+  
(\d{4}|\d{1,2})\w*\b
```

This regex can read dates: YYYY/MM/DD dd/mm/yy Month dd YYYY YYYY/Month

submitted by *anonymous* 8 years ago
submission score of 0


R

<https://regex101.com>

DATA STORAGE


- Bases de datos relacionales y no relacionales
- Data lakes • Data warehouses • Data mart

Different between data types

	 Database	VS  Data Warehouse	VS  Data mart	VS  Data lake
Scope	Application-specific	Organization-wide, structured data.	Department-specific, structured data.	Organization-wide, any type of data
Data Type	Structured	Structured	Structured	Structured, semi-structured, unstructured.
Structure	Predefined schema	Schema on write	Schema on write (inherited from data warehouse)	Schema on read
Use Case	Operational applications(OLTP)	Business intelligence, historical analysis(OLAP).	Specific business function analysis	Big data analytics, data exploration.


<https://www.linkedin.com/pulse/differences-between-database-vs-data-warehouse-mart-lake-nguyen-tuan-ejo7c/>

<https://factor-bytes.com/2023/06/25/choosing-the-right-data-storage-solution-database-vs-data-lake-vs-data-warehouse/>





<https://www.holistics.io/blog/data-lake-vs-data-warehouse-vs-data-mart/>

- Soluciones de almacenamiento en la nube




DATA BASES

Criterio	Relacional (SQL)	No Relacional (NoSQL)	Orientada a Objetos	Data Warehouse	Temporal
Modelo de datos	Tablas con filas y columnas	Clave-valor, documentos, grafos, columnas	Objetos con atributos y métodos	Tablas optimizadas para análisis	Tablas con manejo de tiempo (validez/transacción)
Ejemplos	MySQL, PostgreSQL, Oracle	MongoDB, Cassandra, Redis, Neo4j	db4o, ObjectDB, Versant	Snowflake, Redshift, BigQuery	TimeScaleDB, Oracle Temporal, SQL Server Temporal
Estructura de datos	Altamente estructurada	Semi/no estructurada	Estructura OO (herencia, polimorfismo)	Estructurada y optimizada para consultas	Estructurada + soporte de tiempo
Escalabilidad	Vertical (más potente un solo servidor)	Horizontal (añadir más nodos)	Limitada, depende del diseño	Horizontal, escalabilidad masiva	Similar a relacionales
Velocidad de consulta	Alta para transacciones estructuradas	Alta en lectura/escritura sin joins complejos	Depende del motor y modelo	Alta en lecturas analíticas complejas	Alta para historial y comparación temporal
Integridad referencial	Soportada (joins, claves foráneas)	Limitada o inexistente según el tipo	Soportada entre objetos	Limitada o controlada externamente	Soportada con metadatos temporales
Transaccionalidad (ACID)	Fuerte soporte ACID	A menudo BASE (flexible, eventual consistency)	Depende del motor	Lecturas consistentes, menos enfoque en escritura	Similar a relacionales o configurable
Casos de uso típicos	ERP, CRM, banca, sistemas contables	IoT, redes sociales, big data, apps móviles	Aplicaciones OO puras, CAD, simulación	BI, análisis financiero, reporting	Auditoría, trazabilidad, cumplimiento legal
Ventajas principales	Madurez, soporte, integridad	Flexibilidad, escalabilidad, rendimiento	Cercano a lenguajes de programación	Optimizado para análisis y reportes masivos	Gestión automática de cambios y versiones
Desventajas	Poca flexibilidad con datos no tabulares	Menos consistencia, complejidad de diseño	Poco adoptadas, limitada interoperabilidad	No es ideal para operaciones transaccionales	Mayor complejidad y uso de espacio



DATA INTEGRATION

- ETL (Extracción, Transformación y Carga)
- ELT (Extracción, Carga y Transformación)
- Data federation
- APIs y web services para integración en tiempo real




<https://ridgeant.com/blogs/etl-vs-elt-comparison/>

<https://landing.bismart.com/etl>

Proceso	¿Dónde se transforma?	¿Cuándo se transforma?	¿Cuándo utilizarlo?	Ejemplo
ETL	Fuera del destino (en motor intermedio)	Antes de cargar	Sistemas clásicos, integración completa, limpieza previa	Una empresa bancaria limpia y valida sus datos de transacciones (quita duplicados, corrige formatos) antes de cargarlos a su almacén de reportes financieros
ELT	Dentro del destino (por ejemplo, un Data Warehouse)	Después de cargar	Big Data, Cloud, almacenamiento barato, transformación masiva en SQL	Una startup carga todos sus eventos de usuario en bruto a BigQuery y luego los transforma usando SQL para generar dashboards y modelos de machine learning

DATA INTEGRATION


- ETL (Extracción, Transformación y Carga)
- ELT (Extracción, Carga y Transformación)
- Data federation
- APIs y web services para integración en tiempo real



<https://www.geeksforgeeks.org/database-federation-system-design/>

DATA INTEGRATION

- ETL Software




Need an ETL/ELT connector and don't want to search for it? [Portable](#) builds integrations on-demand for clients

<https://portable.io/learn/best-etl-tools>

<https://www.geeksforgeeks.org/database-federation-system-design/>


DATA INTEGRATION

- ETL (Extracción, Transformación y Carga)
- ELT (Extracción, Carga y Transformación)
- Data federation
- APIs y web services para integración en tiempo real



<https://www.astera.com/pt/type/blog/types-of-apis/>

DATA INTEGRATION



RECOMENDACIONES



coursera



 **udemy**

RECOMENDACIONES

